基于 ResNet18 的眼底图像多标签分类

Project 3 实验报告

组别	第 ___ 组	姓名	_____
学号	_____	日期	2026-10-27

本实验在 Fundus 眼底图像数据集上训练了一个分类模型，完成 20 类多标签预测，并按课程要求以 CSV 形式提交测试集结果。模型走选项一（CNN-based model），使用 ImageNet 预训练的 ResNet18。

验证集 macro AUC	验证集 micro AUC	参数量	训练设备
0.9264	0.9426	11.2 M	CPU（12 线程）

1 任务与数据

本任务是一个 多标签（multi-label） 图像分类问题：每张眼底图像可以同时具有多个病灶标签（如 DR、MH、ODC），也可以带有 NORMAL 标签。数据集共 2208 张 300×300 RGB PNG 图像，官方划分为训练集 1545 张、验证集 221 张、测试集 442 张，三者互不重叠。

数据有两个比较明显的特点，后面的建模和评估方式基本是围绕它们定的：

- 类别极不均衡：最多的 DR / NORMAL 各 346 张，最少的 CRS 仅 21 张，相差约 16 倍。
- 多数图像只有单一标签：1545 张训练图中 1194 张只有 1 个标签，295 张有 2 个，52 张有 3 个，4 张有 4 个，没有无标签图像。
- 存在长尾难类：OTHER 为兜底类别，语义异质性最强；ODP、LS、ASR、CRS 等样本量均不足 50。

表 1 训练集标签分布（共 20 类，只列出前后各 8 类）

标签	训练	验证	标签	训练	验证
DR	346	50	RS	40	6
NORMAL	346	49	ODE	40	6
ODC	184	26	CRVO	38	6
OTHER	183	26	LS	32	5
MH	118	17	CSR	25	4
DN	114	16	HTR	24	4
ARMD	110	16	ASR	23	3
TSLN	109	16	CRS	21	3

验证集只有 221 张，少数类别的正样本只有 3–6 张，单类 AUC 的方差会比较大。所以我们用 macro AUC（各类 AUC 的平均）来选模型，它不会被样本多的类别带偏，更适合这种长尾的多标签任务。

2 模型介绍

本实验选用 ResNet18（He et al., CVPR 2016）作为主干网络。网络由 1 个 7×7 卷积下采样层、4 个 stage（每个 stage 由 2 个 BasicBlock 组成，通道数依次为 64/128/256/512）、全局平均池化层和全连接层构成，共 18 层带权重的层，参数量约 11.2 M。

ResNet 的核心是残差连接：BasicBlock 学习残差函数 F(x)，输出为 F(x) + x。恒等捷径（identity shortcut）为梯度提供了直通通路，缓解了深层网络的梯度消失与退化问题，使网络在较深时仍然容易优化。

针对多标签任务，我们把原始 1000 类全连接层换成 512→20 的线性层，每个标签独立经过 sigmoid 得到存在概率，训练时使用二元交叉熵（BCEWithLogitsLoss）分别监督 20 个二分类器；推理时输出 20 维概率向量，不做标签间互斥约束，从而允许一张图像同时命中多个类别。

3 选择该模型的理由

- 数据规模小，CNN 的归纳偏置更省数据。训练集只有 1545 张，卷积的局部性、平移等变性和层级特征复用是与图像任务高度匹配的先验；Transformer 缺少这种先验，通常需要更大规模数据或更强的正则与蒸馏才能追上。

• 病灶是局部纹理模式。微血管瘤、硬性渗出、出血点等病灶在眼底图上表现为局部的纹理与颜色异常，卷积感受野天然适合建模这类模式；ImageNet 预训练的浅层边缘/纹理特征迁移效果稳定。

• 迁移学习成熟且可解释。ImageNet 预训练 ResNet18 在中小医学影像数据集上被广泛验证，且 Grad-CAM 可直接作用于 layer4 给出空间定位，便于实验报告做定性分析。

• 算力与工程约束。本次实验在 CPU（12 线程）上完成训练。实测 ResNet18 单 epoch 约 1.7 分钟，而 ViT-B/16 单 epoch 约 16 分钟，20 epoch 需要 5 小时以上，不具备可行性。

• 符合“只选一个模型”的要求。ResNet18 结构简单、依赖少、易于复现，避免堆叠多模型带来的工程复杂度，把精力放在训练策略与实验分析上。

4 实现细节与超参数设置

数据使用。训练集（1545 张）用于梯度更新；验证集（221 张）只用于选择模型与统计指标，从未参与任何训练或数据增强，符合“严禁把验证集用于训练”的要求；测试集（442 张）只在最终推理时使用。

表 2 主要超参数与实现设置

配置项	取值	配置项	取值
主干网络	ResNet18	预训练权重	ImageNet-1K
输入尺寸	224×224	batch size	16
损失函数	BCEWithLogitsLoss	优化器	AdamW
初始学习率	3e-4	权重衰减	1e-4
学习率调度	CosineAnnealingLR	epoch	20
随机种子	42	混合精度	未使用（CPU）
训练设备	CPU / 12 线程	单 epoch 耗时	约 105–190 s

训练与模型选择。每个 epoch 结束后在验证集上前向计算 20 个类别的 AUC（跳过验证集中只有单一类别的退化情况），取平均得到 macro AUC，并保存 macro AUC 最高的 checkpoint。最终模型为第 14 epoch，验证集 macro AUC = 0.9264。训练损失从 0.216 稳定下降到 0.013，验证集 AUC 在第 11 epoch 后基本收敛，未出现明显的过拟合拐点。

训练轮数的确定。主干加载了 ImageNet 预训练权重，模型起点较高：第 1 个 epoch 损失即降至 0.15 以下，第 5 个 epoch 的 macro AUC 已达到 0.92，此后指标进入平台期。20 个 epoch 累计约 1900 次参数更新（1545/16 ≈ 97 步/epoch），足以让新的分类头收敛；验证曲线在第 11 epoch 后不再上升，继续训练只会增加过拟合风险。因此本实验不需要从零训练场景下常见的上百个 epoch。

推理与提交。测试集采用水平翻转 TTA（test-time augmentation）：原图与水平翻转图各前向一次，sigmoid 概率取平均，按 sample_submission.csv 的行顺序写出 20 列概率值，列名为官方标签顺序。提交概率而非硬标签，是为了与 AUC 评分保持一致（AUC 只依赖排序）。

5 Tricks（按要求写明）

• ImageNet 预训练迁移：加载 torchvision 官方 ResNet18 的 IMAGENET1K_V1 权重，替换最后的全连接层后整体微调（未冻结任何层）。

• 数据增强：RandomResizedCrop(224, scale=0.85–1.0, ratio=0.9–1.1)、水平翻转（p=0.5）、随机旋转 ±10°、ColorJitter（亮度/对比度 0.2、饱和度 0.1、色相 0.02）。增强只作用于训练集。

- 余弦退火学习率：CosineAnnealingLR，学习率由 3e-4 平滑降到约 0，避免后期震荡。
- 按验证集 macro AUC 选模型：而非按 loss 或 ACC 选，与最终评分指标一致。
- 水平翻转 TTA：推理时对原图与翻转图取平均概率，降低单次预测的方差。
- 未使用的策略：未使用类别加权（pos_weight）、Focal Loss、多模型集成或测试集伪标签；其中集成/多模型与本作业“只需选一个模型”的要求冲突，故主动放弃。

6 实验结果

6.1 整体指标

表 3 验证集整体表现（ACC / F1 按 0.5 阈值计算）

指标	macro AUC	micro AUC	子集准确率	F1 (micro)	F1 (macro)
验证集	0.9264	0.9426	0.5113	0.6454	0.5380

这里有一点容易被误读：数据严重不均衡时，固定 0.5 阈值会把稀有类别的预测压向 0，所以 ACC 和 F1 看起来不高（F1 macro 0.538）。但作业评的是 AUC，它与阈值无关，只看概率排序，更能反映模型真实的判别能力。真要提 F1，做法是在验证集上给每个类别单独搜阈值，不过本报告仍以 AUC 为主指标。

6.2 训练过程

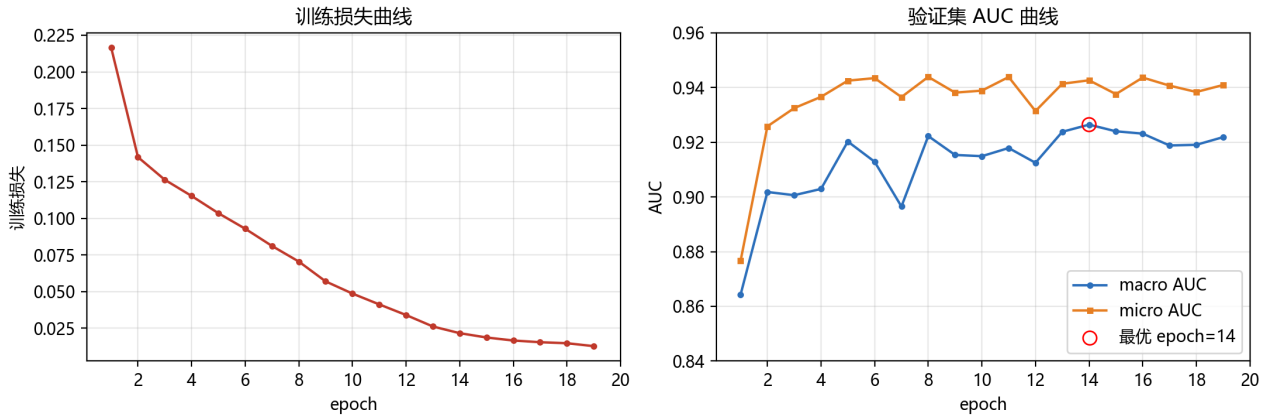


图 1 训练损失与验证集 AUC 随 epoch 的变化（红线圈出最优 epoch）

损失单调下降并在最后几个 epoch 趋于平缓；macro AUC 在第 5 epoch 达到 0.92，第 14 epoch 达到峰值 0.9264，此后在 0.919–0.924 之间小幅波动，说明在 20 epoch 的预算下模型已基本收敛。micro AUC 略高于 macro AUC，主要因为稀有类别被正确地分配了较低的 AUC。

6.3 各类别表现

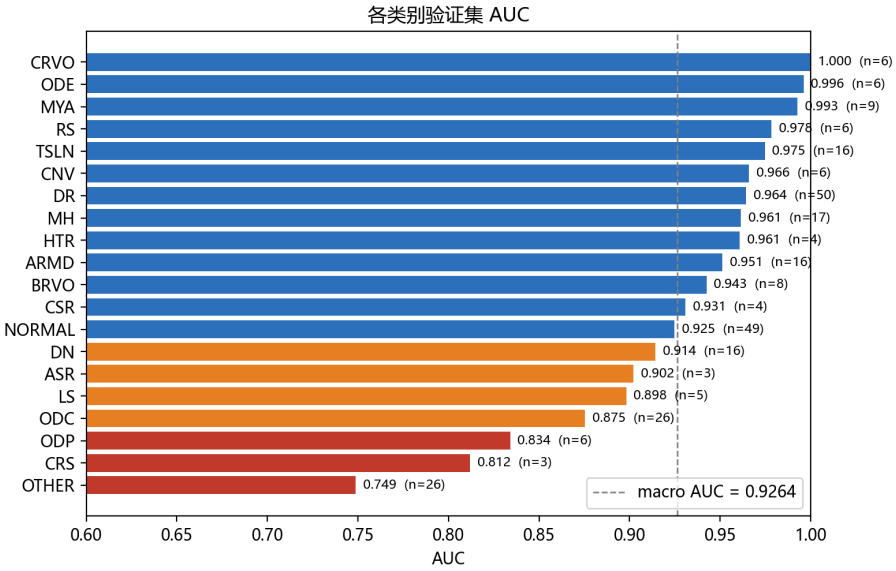


图 2 20 个类别的验证集 AUC（括号内为该类验证集正样本数）

多数类别 AUC 在 0.92 以上；表现最弱的是 OTHER（0.749），因为它是语义异质的兜底类，样本之间缺乏共同视觉模式；其次是 CRS（0.812）与 ODP（0.834），这两类训练样本仅 21 / 44 张，验证集正样本仅 3 / 6 张，单类 AUC 的估计方差很大。常见类别 DR、NORMAL 分别达到 0.964 与 0.925，说明数据量仍是制约长尾类性能的主要因素。

表 4 验证集逐类别指标

类别	正样本	AUC	P@0.5	R@0.5	F1@0.5
CRVO	6	1.0000	1.000	1.000	1.000
ODE	6	0.9961	1.000	0.667	0.800
MYA	9	0.9927	0.857	0.667	0.750
RS	6	0.9783	1.000	0.167	0.286
TSLN	16	0.9747	0.692	0.562	0.621
CNV	6	0.9659	0.750	0.500	0.600
DR	50	0.9643	0.909	0.800	0.851
MH	17	0.9614	0.714	0.588	0.645
HTR	4	0.9608	0.000	0.000	0.000
ARMD	16	0.9512	0.800	0.500	0.615
BRVO	8	0.9425	1.000	0.500	0.667
CSR	4	0.9309	1.000	0.500	0.667
NORMAL	49	0.9247	0.618	0.857	0.718
DN	16	0.9143	0.500	0.438	0.467
ASR	3	0.9021	0.500	0.333	0.400
LS	5	0.8981	1.000	0.200	0.333
ODC	26	0.8753	0.692	0.346	0.462
ODP	6	0.8341	1.000	0.333	0.500
CRS	3	0.8119	0.000	0.000	0.000
OTHER	26	0.7487	0.636	0.269	0.378

6.4 Grad-CAM 可视化

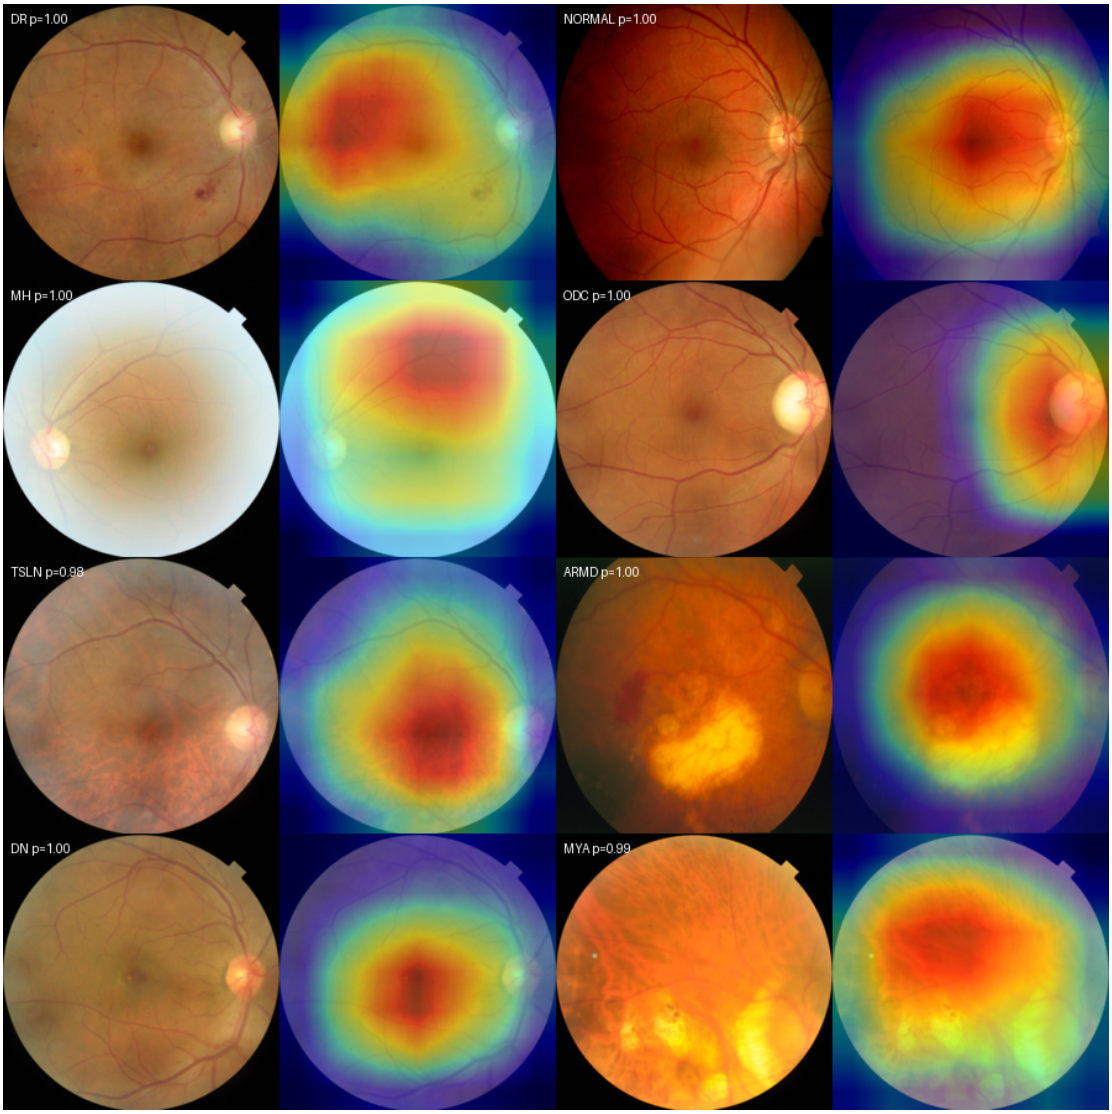


图 3 Grad-CAM：左为原图，右为对应的类激活热图（取验证集中每类置信度最高的样本）

热图显示模型主要关注视盘、黄斑区以及病灶所在的局部区域，而不是整张图像均匀响应，说明网络学到的是与病理相关的结构，而非背景或拍摄伪影。例如 ARMD 的激活集中在黄斑下方的玻璃膜疣状病灶。MYA 的激活集中在后极部大片萎缩区，ODC 的激活集中在视盘附近。这也说明 ResNet18 迁移到眼底图像上是合理的。

7 总结与局限

本实验在 Fundus 眼底图像数据集上训练了一个 ImageNet 预训练的 ResNet18，损失用 BCE，配合数据增强、余弦退火和翻转 TTA，验证集上得到 macro AUC 0.9264、micro AUC 0.9426，在 CPU 上大约 40 分钟训练完成，符合课程“单模型、可用预训练权重、val 不参与训练”的要求。

- 主要局限：训练集仅 1545 张，长尾类别（CRS、HTR、ASR 等）验证集正样本只有 3–5 张，指标波动大；OTHER 类语义混杂，AUC 明显低于其他类别。
- 可改进方向：换更强的预训练主干（如 ConvNeXt、EfficientNet）或医学领域预训练权重；用类别加权 / Focal Loss 缓解长尾；在验证集上做逐类阈值搜索来提 F1；或者把输入分辨率加大到

256/320。这些改动都还在单模型范围内，不违背课程要求。

附录 代码与复现

提交的 Code 目录结构如下，所有随机种子固定为 42，结果可复现：

文件	作用
Code/train.py	数据加载、数据增强、训练与逐 epoch 验证（macro/micro AUC）、保存最优权重
Code/predict.py	加载最优权重，水平翻转 TTA 推理，生成 test.csv
Code/eval_report.py	计算逐类 AUC / P / R / F1 与整体指标，并生成 Grad-CAM 图

复现命令：

```
python Code/train.py --model resnet18 --epochs 20 --out runs/r18_base
python Code/predict.py --ckpt runs/r18_base/best.pt --out test.csv
python Code/eval_report.py --ckpt runs/r18_base/best.pt --outdir
runs/r18_base/report
```